

CiteScope — Reporte Entrega 1 (MicroProyecto)

Equipo (Grupo 8):

- Camilo Bejarano — c.bejaranoc@uniandes.edu.co
- German Rodriguez — gm.rodriguez@uniandes.edu.co
- Jose Arteaga — j.arteagac@uniandes.edu.co
- Sebastian Toro — s.torod@uniandes.edu.co

Curso: Proyecto - Desarrollo de Soluciones / MAIA **Fecha:** Agosto 2026

1. Problema que abordarán y su contexto

Clasificación de la **subárea de Computer Science** de un artículo científico a partir del **contexto de la cita** y de los **metadatos (título y abstract)** del artículo citado.

- **Contexto general:** el volumen de literatura científica en arXiv crece de forma acelerada, lo que dificulta organizar, indexar y descubrir trabajos por su subárea temática. Cuando un artículo cita a otro, el párrafo donde ocurre la cita y los metadatos del trabajo citado ofrecen señales sobre el tema que se está abordando. Este proyecto aprovecha esas señales para inferir automáticamente la subárea de Computer Science del artículo citante.
- **Motivación / valor:** clasificar la subárea permite organizar y navegar grandes colecciones de literatura, apoyar la indexación temática y la recomendación de artículos, y agilizar tareas de revisión bibliográfica al agrupar trabajos por su área de conocimiento sin depender de etiquetas manuales.
- **Dominio:** artículos científicos en inglés de **Computer Science** (arXiv).

2. Pregunta de negocio y alcance del proyecto

Pregunta de negocio:

¿Es posible predecir la subárea de Computer Science (los códigos **cs.*** de arXiv, p. ej. **cs.LG** = *Machine Learning*) de un artículo a partir del contexto de la cita y de los metadatos (título y abstract) del artículo citado?

Alcance (prototipo funcional):

1. **Datos:** dataset supervisado de 4.000 contextos de cita etiquetados por subárea (8 subáreas de Computer Science de arXiv, ver Sección 3), enriquecidos con título y abstract del artículo citado.
2. **Modelo:** clasificador multiclase supervisado (Context-enriched): **citation_context + cited_title + cited_abstract → citing_primary_category** (subárea de Computer Science del citante).
3. **Prototipo tecnológico:**
 - **API** para servir inferencias.
 - **Tablero (dashboard)** que consuma la API y visualice datos relevantes.
 - **Despliegue con Docker** (contenedores).
4. **Limitaciones:**
 - **Sesgo de selección por abstract:** la construcción priorizó registros con abstract disponible (cobertura ~98%), por lo que el dataset no refleja la proporción real de citas sin metadatos y el modelo podría degradarse ante entradas sin título o abstract.
 - **Sesgo de sección:** aunque se aplicó muestreo distribuido, los contextos de cita se concentran en secciones como *Introduction* y *Related Work*, lo que puede sesgar el lenguaje aprendido hacia el estilo de esas secciones.
 - **Dominio acotado a 8 subáreas:** solo se consideran 8 categorías **cs.***; el modelo no reconoce otras subáreas de Computer Science ni disciplinas distintas.
 - **Etiqueta única (single-label):** se asume una sola subárea por artículo (**citing_primary_category**), pese a que muchos trabajos son multidisciplinarios y podrían pertenecer a varias categorías.
 - **Posible fuga de información por obras citadas repetidas:** una misma obra puede aparecer en varias particiones, por lo que la estrategia de partición debe controlarlo para no sobreestimar el desempeño.
5. **Resultados esperados:**
 - **Baseline (solo contexto):** clasificador sobre **citation_context** únicamente, como referencia mínima frente al azar (12,5% en 8 clases balanceadas).
 - **Modelo enriquecido (contexto + título + abstract):** se espera que la adición de los metadatos del artículo citado supere de forma consistente al baseline.
 - **Métrica principal:** *Macro F1* (trata por igual a las 8 clases balanceadas), acompañada de *accuracy* y F1 por categoría; meta orientativa de Macro F1 $\geq 0,70$ para el modelo enriquecido, a confirmar con la evaluación.
 - **Entregable:** matriz de confusión y desempeño por subárea para identificar categorías más difíciles y confusiones entre áreas cercanas (p. ej. **cs.AI**, **cs.LG** y **cs.NE**).

Fuera de alcance (por ahora):

- Clasificación de la *función* de la cita.
- Recuperación semántica del texto completo del artículo citado.
- Predicción multi-etiqueta (un artículo se asigna a una sola subárea).
- Subáreas de arXiv fuera de las 8 seleccionadas y disciplinas distintas a Computer Science.
- Artículos en idiomas distintos al inglés.

3. Descripción de los conjuntos de datos

3.1 Exploración de fuentes candidatas

Antes de decidir se evaluaron cuatro fuentes bajo la restricción de dominio (**Computer Science / arXiv**). La tabla resume el hallazgo crítico y la decisión:

Dataset	Dominio	Hallazgo crítico	Decisión
SciCite	Mayormente biomédico	Solo 3 clases defunción de cita; ~1.7% de citas enlazables a arXiv	Descartado
ACL-ARC	CS / NLP	Muy pequeño (~1.9k); 65% de citas "External"; abstract del citado ~21%	Referencia secundaria
MultiCite	CS / NLP	IDs de paper anonimizados (hash de 30 chars) → el citado no es resoluble	Descartado
unarXive	arXiv (CS-heavy)	Ninguno crítico; texto completo + citas resueltas a IDs reales	Seleccionado

Por qué unarXive: es nativo de arXiv (filtrable por `discipline == "Computer Science"`), trae el texto completo estructurado y resuelve cada cita a identificadores reales del artículo citado (OpenAlex / DOI), lo que habilita el enriquecimiento con título y abstract. Además, el mismo corpus se reutiliza en el Proyecto de Grado (recuperación de texto completo por el arXiv ID del citado).

El detalle completo de la exploración y los motivos de descarte está en [Dataset/Resumen_Seleccion_Dataset.md](#).

3.2 Fuentes de datos

Fuente primaria — unarXive (open subset): corpus de arXiv preprocesado para NLP (texto completo estructurado + red de citas). Zenodo, registro 7752615, [unarXive_230324_open_subset.tar.xz](#) (4.8 GB), licencia CC BY-SA 4.0.

Fuente de enriquecimiento — OpenAlex: título y abstract del artículo citado, resueltos por su `open_alex_id` (el abstract se reconstruye desde el `abstract_inverted_index`). Como un párrafo (`citation_context`) puede contener varias citas, a nivel de registro se toma la **primera cita del párrafo que tenga abstract** disponible (y si ninguna lo tiene, la primera con título); esto maximiza la cobertura de abstract del dataset.

3.3 Construcción del dataset (pipeline en 3 etapas)

El dataset se construyó con un pipeline reproducible (scripts en `scripts/`):

```
unarXive (corpus local, CS)
  | Etapa 1 – harvest_candidates.py
  ▼
Candidatos con excedente por clase (7.103 candidatos)
  | Etapa 2 – enrich_select.py (OpenAlex: title + abstract)
  ▼
Enriquecimiento del artículo citado
  | Etapa 3 – enrich_select.py (selección balanceada)
  ▼
Dataset final 8 × 500 = 4.000 registros
```

- **Etapas 1 — Cosecha:** recorrido del corpus filtrando `Computer Science`, con **muestreo distribuido por secciones** (reduce el sesgo de "Introduction"), **anti-memorización** (máx. 4 contextos por artículo), deduplicación y longitud mínima de 200 caracteres. El marcador `{{cite:...}}` se normaliza a `[CIT]`. Resultado: ~165.000 artículos escaneados, **1.807** de CS usados, **7.103** candidatos cosechados (con excedente).
- **Etapas 2 — Enriquecimiento:** resolución de título/abstract del citado vía OpenAlex, con preferencia de selección a registros que tienen abstract.
- **Etapas 3 — Selección balanceada:** 500 registros por clase (8 × 500 = 4.000), con tolerancia de balance ±10%; el resultado cumplió el balance exacto.

Dataset resultante: `unarxive_microproyecto.jsonl` — 4.000 registros, 8 subáreas × 500 (balanceado).

Campo	Rol	Descripción
<code>citation_context</code>	Input (X)	Párrafo del citante con la cita (marcador → <code>[CIT]</code>)
<code>cited_title</code>	Input (X)	Título del artículo citado
<code>cited_abstract</code>	Input (X)	Abstract del artículo citado
<code>citing_primary_category</code>	Target (y)	Subárea de Computer Science (<code>cs.*</code>) del citante
<code>section / sec_type</code>	aux	Sección del citante donde ocurre la cita

Campo	Rol	Descripción
<code>cited_refs[]</code>	aux	Todas las citas del párrafo con sus IDs

Subáreas (target): las 8 subáreas de Computer Science de arXiv usadas como etiquetas de clasificación.

Código arXiv	Nombre de la subárea
<code>cs.LG</code>	Machine Learning (aprendizaje automático)
<code>cs.CV</code>	Computer Vision and Pattern Recognition (visión por computador)
<code>cs.CL</code>	Computation and Language (procesamiento de lenguaje natural)
<code>cs.AI</code>	Artificial Intelligence (inteligencia artificial)
<code>cs.NE</code>	Neural and Evolutionary Computing (cómputo neuronal y evolutivo)
<code>cs.RO</code>	Robotics (robótica)
<code>cs.IR</code>	Information Retrieval (recuperación de información)
<code>cs.MA</code>	Multiagent Systems (sistemas multiagente)

Disponibilidad: el dataset está versionado con **DVC**. El repositorio Git contiene el puntero

`Dataset/unarxive_microproyecto.jsonl.dvc`; el archivo de datos (`unarxive_microproyecto.jsonl`, ~20,3 MB, MD5

`ab4dae83062d1de3238c419cbd3d3a4c`) se almacena en un remoto **S3** (`s3://gaspar3107-tech-taller3-dvc-`

`20260816/maia4401-microproyecto`, región `us-east-1`). Para obtenerlo: clonar el repositorio y ejecutar `dvc pull` (requiere credenciales de acceso al bucket).

4. Exploración de los datos (EDA)


Resumen de los principales hallazgos verificados durante la construcción:

- **Balance de clases:** 500 registros por subárea ($8 \times 500 = 4.000$).
- **Cobertura de `cited_title`:** 97,9 % · **`cited_abstract`:** 98,1 %.
- **Distribución por sección:** Introducción ~25% (resto: Related Work, Discussion, Experiments, Results, ...).

4.1 Visualizaciones principales


Distribución de las clases

Las ocho subáreas se encuentran balanceadas, con 500 observaciones por clase.




Longitud del contexto de cita

La distribución de la longitud permite identificar el tamaño típico de los contextos y la existencia de registros considerablemente más extensos.




Distribución de las secciones

Esta visualización muestra en qué tipos de sección aparecen los contextos de cita seleccionados para el conjunto de datos.




Número de citas por párrafo

La gráfica resume cuántos marcadores de cita contiene cada contexto y permite observar la concentración de párrafos con una o pocas referencias.



Referencias citadas y subáreas

El mapa de calor relaciona las referencias citadas con las categorías objetivo. Permite identificar obras asociadas principalmente con una subárea y referencias transversales a varias comunidades. También evidencia el posible riesgo de fuga de información si una misma obra aparece en las particiones de entrenamiento y prueba.



Nota: esta sección presenta los principales resultados del análisis exploratorio. Para consultar las tablas, validaciones, cálculos y visualizaciones con mayor detalle, véase el notebook [AnálisisEDA.ipynb](#).

5. Maqueta (mockup) del prototipo

Elementos previstos del prototipo:

- **Entrada:** campo para pegar el contexto de la cita (+ opcional título y abstract del citado).
- **Salida:** subárea **CS.*** predicha + probabilidades por clase.
- **Visualizaciones:** distribución de predicciones, confianza del modelo, métricas de evaluación, actividad de la API y detalle de las inferencias realizadas.
- **Relación con la pregunta de negocio:** el tablero permite probar si el contexto de la cita y los metadatos del artículo citado contienen información suficiente para asignar una de las ocho subáreas. Además de presentar la categoría predicha, permite inspeccionar la incertidumbre del modelo y monitorear su comportamiento después del despliegue.

5.1 Vistas propuestas

El prototipo tendrá tres vistas principales:

1. **Clasificar cita:** formulario con **citation_context**, **cited_title** y **cited_abstract**. La respuesta mostrará la subárea predicha, su nombre completo, la confianza y las probabilidades para las ocho categorías.
2. **Monitoreo:** resumen de las predicciones atendidas por la API y su evolución en el tiempo.
3. **Evaluación del modelo:** métricas calculadas sobre un conjunto etiquetado, incluyendo Macro F1, accuracy, precision, recall, F1 por categoría y matriz de confusión.

La confianza de una inferencia no se presentará como una medida de exactitud. Las métricas de desempeño requieren una etiqueta real y se calcularán inicialmente sobre el conjunto de prueba. Cuando una predicción en producción reciba una etiqueta validada, podrá incorporarse a las métricas de producción.

5.2 Registro de inferencias de la API

Cada solicitud atendida por la API generará un registro de monitoreo. Como mínimo, el registro tendrá:

Campo y descripción	Campo y descripción	Campo y descripción
prediction_id ID único	**timestamp** Fecha y hora	**model_version** Versión del modelo
predicted_category Subárea predicha	**confidence** Probabilidad principal	**class_probabilities** Probabilidades por categoría
latency_ms Tiempo de respuesta	**has_cited_title** Disponibilidad de título	**has_cited_abstract** Disponibilidad de abstract
citation_context_length Longitud del contexto	**status** Éxito o error	**actual_category** Etiqueta real, si existe

El almacenamiento del texto completo será configurable. Para reducir riesgos de privacidad, el monitoreo puede conservar únicamente características derivadas, como longitudes, presencia de metadatos y un hash de la entrada.

5.3 Tablero de monitoreo

La parte superior mostrará tarjetas con indicadores del periodo seleccionado:

- total de peticiones;
- predicciones exitosas y tasa de error;

- latencia promedio y percentil 95;
- confianza promedio;
- porcentaje de predicciones de baja confianza;
- categoría predicha con mayor frecuencia;
- porcentaje de entradas sin título o sin abstract.

El tablero incluirá una gráfica temporal del volumen de solicitudes, una gráfica de barras con la distribución de categorías predichas y una distribución de la confianza. Estas métricas permiten monitorear el uso y comportamiento del servicio, pero no reemplazan las métricas de desempeño obtenidas con etiquetas reales.

5.4 Historial y detalle de peticiones

El tablero tendrá un listado paginado de peticiones con las columnas:

Fecha y hora	ID	Categoría predicha	Confianza	Latencia	Estado	Versión
2026-08-20 14:30	pred_001	cs.CV	82%	135 ms	Exitosa	v1.0.0

El listado permitirá filtrar por:

- rango de fechas;
- categoría predicha;
- estado de la petición;
- versión del modelo;
- nivel de confianza.

Al hacer clic sobre una petición se abrirá un panel de detalle con:

- fecha, identificador, estado y versión del modelo;
- disponibilidad y longitud de los campos de entrada;
- categoría predicha y nombre completo de la subárea;
- gráfica de probabilidades para las ocho categorías;
- diferencia entre las dos categorías con mayor probabilidad;
- latencia de la petición;
- etiqueta real y resultado correcto/incorrecto, si ya existe validación;
- opción de registrar retroalimentación o categoría corregida.


Cuando exista una etiqueta real, el detalle permitirá establecer si la predicción fue correcta y cómo contribuye a las métricas del modelo. Cuando no exista, la interfaz indicará **"Resultado aún no validado"** para evitar interpretar la confianza como desempeño comprobado.

5.5 Boceto de navegación

Los mockups de las pantallas propuestas se presentan en la [Sección 8](#). Estos muestran el flujo desde la página de inicio hasta la clasificación, el monitoreo de peticiones, el detalle de una inferencia y la evaluación del modelo.

5.6 Arquitectura propuesta

Se propone una arquitectura modular basada en servicios, desplegada mediante contenedores Docker. La interfaz web no accede directamente al modelo ni a la base de datos: todas las operaciones se realizan a través de una API REST. Esta separación permite actualizar la interfaz, el modelo o el mecanismo de persistencia sin modificar los demás componentes.



Los componentes principales son:

1. **Interfaz web / Dashboard:** implementa las vistas de inicio, clasificación, monitoreo, detalle de petición y evaluación. Envía las solicitudes a la API y presenta las respuestas, pero no ejecuta directamente el modelo.
2. **API REST de inferencia:** recibe `citation_context`, `cited_title` y `cited_abstract`; valida la solicitud; ejecuta el flujo de preprocesamiento y devuelve la categoría predicha, la confianza y las probabilidades de las ocho subáreas.
3. **Preprocesamiento y modelo:** aplica las mismas transformaciones usadas durante el entrenamiento y carga un artefacto versionado del clasificador. Cada respuesta identifica la versión del modelo utilizada.
4. **Registro de inferencias:** almacena el identificador, fecha, versión del modelo, categoría, probabilidades, latencia, estado y características derivadas de la entrada. El texto completo solo se conservará si la política de privacidad lo permite.
5. **Módulo de monitoreo:** consulta los registros para calcular volumen de peticiones, distribución de predicciones, confianza, latencia, errores y disponibilidad de metadatos. También soporta los filtros por fecha y categoría.
6. **Módulo de evaluación:** calcula accuracy, Macro F1, Micro F1, métricas por clase y matriz de confusión utilizando únicamente datos con etiquetas reales.

7. **Versionamiento de datos y artefactos:** Git administra el código y DVC controla las versiones del dataset, las particiones y los artefactos necesarios para reproducir el entrenamiento y la evaluación.

6. Repositorios (código y datos)

6.1 Repositorio de código y documentación (Git)

El código, los scripts reproducibles, el reporte y los recursos visuales se administran en Git. El repositorio remoto del equipo es:

https://github.com/germarodr/MAIA4401_MicroProyecto

Se emplea la rama **dev** para integrar el trabajo en curso del equipo. El historial de commits evidencia, entre otros avances, la inicialización de Git y DVC, el versionamiento inicial del dataset, la selección y el enriquecimiento de unarXive, la construcción del EDA, los mockups y las actualizaciones del reporte.

Evidencia de trazabilidad. La siguiente captura presenta el historial de commits de la rama **dev**, incluyendo contribuciones relacionadas con DVC, el dataset, el EDA, los mockups y el reporte.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> git log origin/dev -20 --pretty=format:
412c3d4 | 2026-08-22 | Sebastian Toro | sebas toro: cambios pendientes mas arquitectura
9e6e231 | 2026-08-22 | German Rodriguez | Agrega tareas de German en reporte de trabajo en equipo (Sección 7)
5238afe | 2026-08-22 | German Rodriguez | Agrega tareas de German en reporte de trabajo en equipo (Sección 7)
5708cfa | 2026-08-22 | German Rodriguez | Completa Sección 2 (limitaciones y resultados esperados) y Disponibilidad DVC en Entrega1
fecab37 | 2026-08-22 | German Rodriguez | Actualiza reporte Entrega1: contexto independiente, motivacion, limitaciones y resultados esperados
1c5c9b4 | 2026-08-21 | Sebastian Toro | sebas toro: mockups y eda
271d266 | 2026-08-20 | German Rodriguez | Actualiza selección de dataset (unarXive), enriquece sección 3 del reporte y agrega scripts de harves
t/enrich
c4b3a6c | 2026-08-20 | gaspar3107-tech | chore: ignore Local SSH key
e92f6df | 2026-08-20 | Jose Gaspar Arteaga Camacho | data: versionar dataset unarxive inicial
44f4cae | 2026-08-20 | Jose Gaspar Arteaga Camacho | Configuración remoto S3 para microproyecto
2fbabea | 2026-08-20 | Ubuntu | Inicializacion de DVC
94d5419 | 2026-08-19 | German Rodriguez | Primeros archivos para Entrega1
```

6.2 Versionamiento y disponibilidad de datos (DVC)

Los archivos de datos se gestionan con **DVC** para separar los archivos pesados del historial de código de Git. El dataset principal, **Dataset/unarxive_microproyecto.jsonl** (4.000 registros; 21.283.237 bytes), está referenciado por el archivo **Dataset/unarxive_microproyecto.jsonl.dvc**. Este puntero registra su ruta, tamaño y hash MD5, permitiendo recuperar exactamente la misma versión del dataset.

El remoto predeterminado de DVC se denomina **aws-remote** y utiliza un bucket privado de Amazon S3 en la región **us-east-1**. La configuración del remoto se mantiene en **.dvc/config**; las credenciales se conservan fuera del repositorio y no se incluyen en Git. En un entorno con permisos para el bucket, el conjunto de datos se reproduce después de clonar el repositorio mediante:

URI del remoto DVC (privado): **s3://gaspar3107-tech-taller3-dvc-20260816/maia4401-microproyecto**

Evidencia de incorporación al control de datos. La Figura siguiente muestra la ejecución de **dvc add**, que calcula la versión del archivo y actualiza el puntero **Dataset/unarxive_microproyecto.jsonl.dvc** para que este pueda ser registrado en Git.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc add Dataset\unarxive_microproyecto
.jsonl
100% Adding... [1/1 [00:00, 3.93file/s]]

To track the changes with git, run:

    git add 'Dataset\unarxive_microproyecto.jsonl.dvc'

To enable auto staging, run:

    dvc config core.autostage true
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto>
```

Evidencia de sincronización con el remoto. La siguiente captura muestra la ejecución de **dvc push**. El mensaje *Everything is up to date* confirma que la versión local del dataset ya se encuentra sincronizada con el remoto DVC.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc push
Collecting [1.00 [00:00, 122entry/s]]
Pushing
Everything is up to date.
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto>
```

6.3 Estructura y evidencias de trazabilidad

La estructura relevante del repositorio comprende:

- **Dataset/**: puntero DVC, resumen y dataset recuperado.
- **scripts/**: scripts de selección, recolección y enriquecimiento de datos.
- **eda/**: notebook y visualizaciones del análisis exploratorio.
- **mockups/**: recursos de la propuesta de interfaz.
- **Reportes/**: documento de la entrega.
- **.dvc/**: configuración del control de versiones de datos.

Inicialización de Git y DVC. Evidencia de que ambos sistemas reconocen la raíz del proyecto.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> git rev-parse --is-inside-work-tree
true
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> git log --reverse --oneline -5
5700cfa Completa Sección 2 (limitaciones y resultados esperados) y Disponibilidad DVC en Entrega1
5230afe Agrega tareas de German en reporte de trabajo en equipo (Sección 7)
9e6e231 Agrega tareas de German en reporte de trabajo en equipo (Sección 7)
412c3d4 sebas toro: cambios pendientes mas arquitectura
f7ece45 (HEAD -> dev, origin/dev) sebastoro: ajstutes de forma
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc root
.
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc --version
3.67.1
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> |
```

Dataset versionado. El archivo `.dvc` registra el hash, tamaño y ruta de la versión controlada.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> Get-Content Dataset\unarchive_microproy
ecto.jsonl.dvc
outs:
- mds: ab4dae83062d1de3238c419cbd3d3a4c
  size: 21283237
  hash: mds
  path: unarchive_microproyecto.jsonl
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc status
Data and pipelines are up to date.
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> |
```

Remoto S3. DVC identifica el remoto privado `aws-remote` configurado para los datos.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> dvc remote list
aws-remote s3://gaspar3107-tech-taller3-dvc-20260816/maia4401-microproyecto (default)
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> |
```

Estructura del repositorio. Evidencia de la estructura en Git del microproyecto.

```
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> git ls-tree --name-only HEAD
.dvc
.dvcignore
.gitignore
Dataset
Reportes
eda
mockups
scripts
(.venv) PS D:\Documentos\4. Courses\1. Master AI\1. Semesters\4 Semester\1 Bimestre\Grado_Microproyecto> |
```

7. Reporte de trabajo en equipo (máx. 1 página)

Integrante	Tareas
Camilo Bejarano	Validación y enmarcado del problema, diseño de la arquitectura de la API a desarrollar y validación cruzada del entregable de Sebastian. Commits: 414b556 .
German Rodriguez	Validación problema de negocio/técnico; creación repositorio Git; selección del dataset (unarXive) y pipeline de datos (harvest/enrich); reporte (Secciones 1–3); revisión cruzada del EDA. Commits: 94d5419 , 271d266 , fecab37 , 5700cfa .
Jose Arteaga	Configuración de DVC y de su remoto privado en S3; versionamiento inicial del dataset unarXive y verificación de su recuperación reproducible con DVC. Commits: 2fbabea , 44f4cae , e92f6df , c4b3a6c .
Sebastian Toro	Realicé los mockups, el tablero de análisis exploratorio (EDA) y la arquitectura; agregué estas secciones al entregable; además validé la entrega de Camilo (validación cruzada). Commits: 1c5c9b4 , 412c3d4 , f7ece45 .

8. Mockups del prototipo

Las siguientes imágenes presentan la propuesta visual de CiteScope. Los datos, predicciones y métricas mostrados son ilustrativos; en la implementación final deberán obtenerse desde la API, el registro de inferencias y los resultados reales de evaluación del modelo.


8.1 Página de inicio

Presenta el propósito del proyecto, los accesos a sus funcionalidades principales, los integrantes del equipo y el apoyo de la Universidad de los Andes.




8.2 Clasificación de una cita

Permite ingresar el contexto de la cita, el título y el abstract del artículo citado. La salida muestra la subárea predicha, la confianza y las probabilidades de las ocho categorías.




8.3 Monitoreo de la API

Resume el volumen de peticiones, la confianza promedio, la latencia y los errores. También incluye filtros por fecha y categoría, junto con el historial de inferencias.




8.4 Detalle de una petición

Muestra la información de una inferencia seleccionada, sus probabilidades, metadatos de entrada, versión del modelo y estado de validación.



8.5 Evaluación del modelo

Presenta las métricas calculadas con datos etiquetados, incluyendo Macro F1, accuracy, matriz de confusión y desempeño por subárea.



8.6 Referencias y anexos

- Saier, T., Krause, J., Färber, M. (2023). *unarXive 2022: All arXiv Publications Pre-Processed for NLP, Including Structured Full-Text and Citation Network*. JCDL '23.
- OpenAlex. <https://openalex.org/>